KIẾN TRÚC TIỀN XỬ LÝ DỮ LIỆU ĐA NGUỒN & XÂY DỰNG BỘ DỮ LIỆU VÀNG

Đề án: Phân tích thị trường lao động IT & Kỹ năng nghề nghiệp tại Việt Nam

Môn học: Khai phá Dữ liệu (Data Mining)

Quy mô: 10,024 bài đăng thô $\rightarrow$ 8,967 bài đăng Golden Master

Học viên thực hiện: Nhóm Nghiên cứu VN-IT-Job-Mining

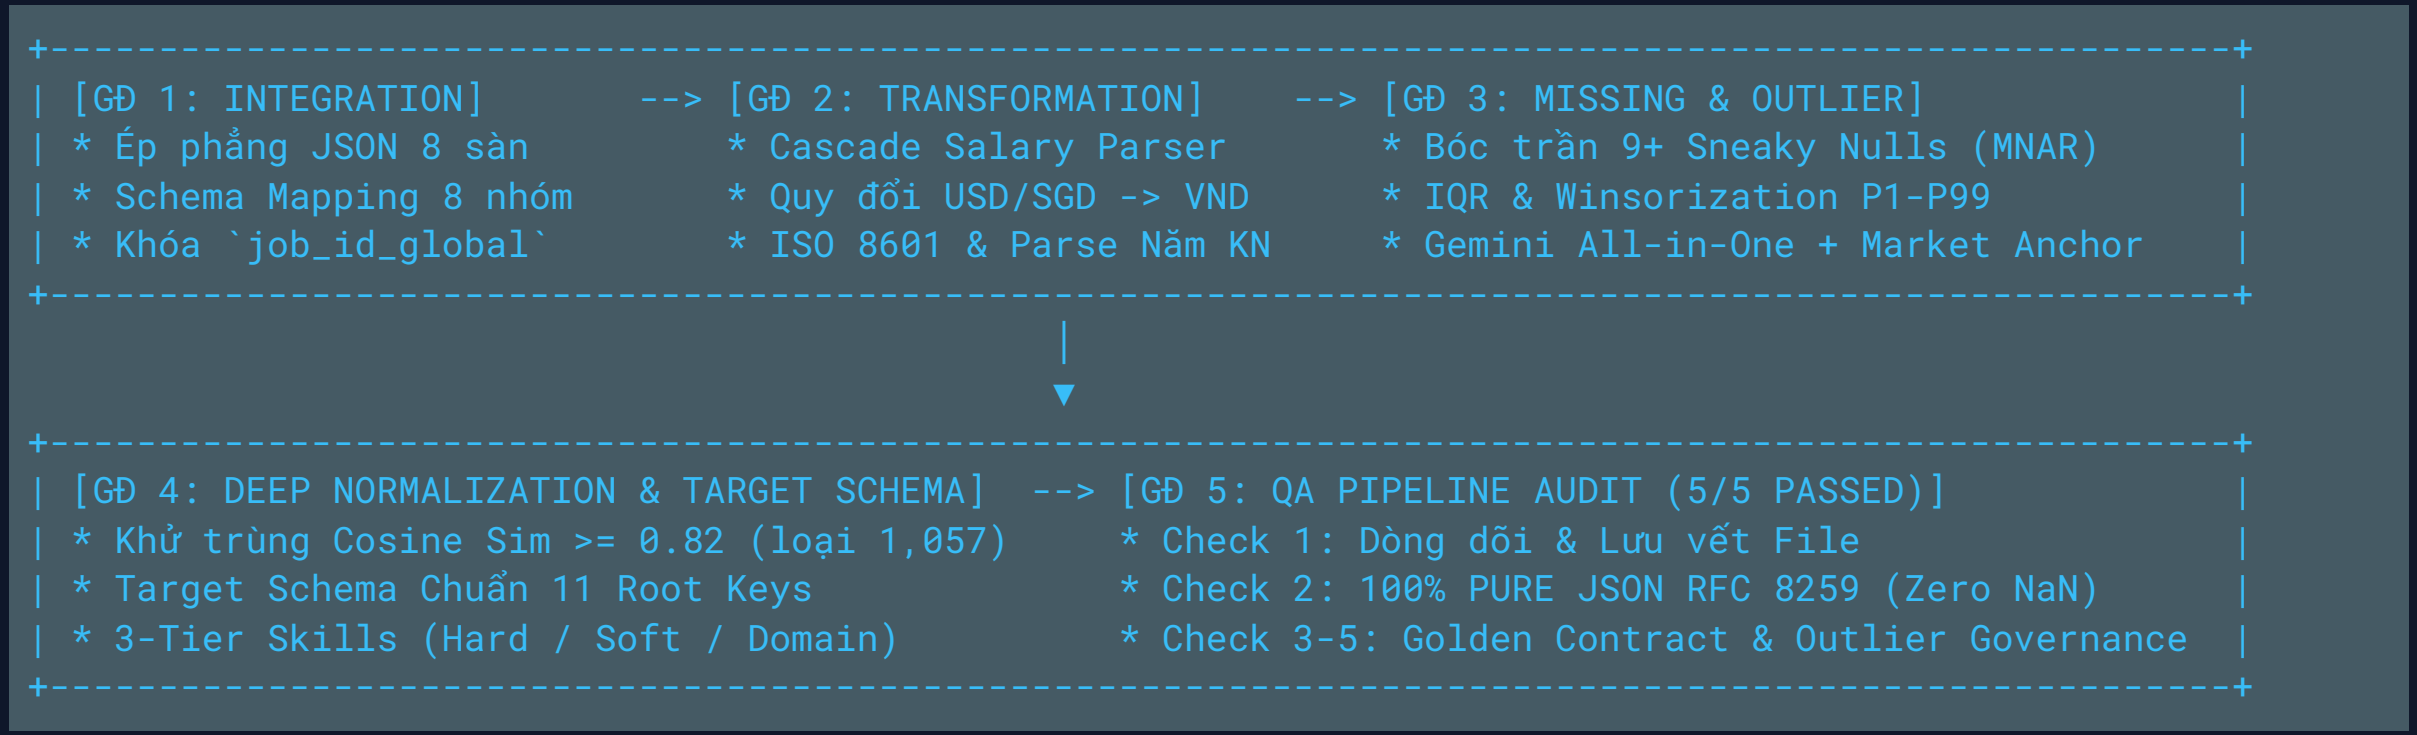
Thời gian: Tháng 10/2026

1. Bối Cảnh Thực Tế & Thách Thức Dữ Liệu IT

- **Quy mô thu thập:** 10,024 bài đăng từ **8 sàn tuyển dụng hàng đầu** (TopCV, TopDev, VietnamWorks, ITviec, CareerViet, Vieclam24h, Glints, JobsGO).
- **Đặc tính dữ liệu thực tế (Real-world Data Sins):**
  - **Cấu trúc dị thể nặng:** JSON lồng nhau 3-4 tầng, mảng tags, detail-box HTML, JSON-LD ngầm.
  - **Lương che giấu & Lương ẩn:** 65% ghi *"Thỏa thuận"*, nhưng lương thực tế nằm rải rác trong câu chữ mô tả công việc (JD).
  - **Sneaky Nulls:** 9+ dạng null trá hình (`"thỏa thuận"` , `"cạnh tranh"` , `0` , `[]` , `"null"`).
  - **Ngoại lai nhập liệu:** Bắt nhầm số điện thoại (SĐT `0243.936...` thành 243 triệu VND) hoặc chuỗi che giấu (`1*** USD`).
  - **Trùng lặp xuyên sàn:** Cùng 1 vị trí tuyển dụng nhưng được HR đăng đồng thời lên 3-4 sàn khác nhau.

2. Kiến Trúc Pipeline Hiện Đại & Ranh Giới Đanh Thép

Quy trình tiền xử lý được chuẩn hóa theo **CRISP-DM nâng cấp ELT** với **4 Giai đoạn liên hoàn**:



- **Khế ước Ranh giới đanh thép (Ironclad Boundaries):** Bước trước không lấn sân bước sau (Integration cấm parse lương, Transformation cấm xóa outlier).

3. Giai Đoạn 1: Tích Hợp Schema & Ép Phẳng JSON

- **Mục tiêu:** Gom 8 nguồn dữ liệu hoàn toàn khác biệt về cấu trúc thành một Bảng phẳng Staging thống nhất (`raw_for_outlier.json`).
- **Kỹ thuật cốt lõi:**
  - **Recursive JSON Flattener:** Đệ quy giải mã dict lồng nhau, mảng đối tượng, thuộc tính DOM table và thẻ JSON-LD ngầm.
  - **Khóa toàn cục định danh duy nhất:**

$$\text{job_id_global} = \langle \text{source_platform} \rangle _ \langle \text{source_job_id} \rangle$$

  - **Ánh xạ 8 Nhóm Thuộc Tính Cốt Lõi:**
    `company` , `địa điểm` , `skills` , `JD` , `salary` , `date` , `requirements` , `other` .
- **Nguyên tắc bất biến:** 100% Deterministic logic. Tuyệt đối **không** dùng AI, **không** xóa hàng, **không** fillna tại bước này.

4. Giai Đoạn 2: Cascade Salary Parser & Bóc Tách Kiểu

- **Bài toán:** 65% bài đăng ghi *"Lương Thỏa thuận"* ở tiêu đề nhưng lại nêu mức lương cụ thể trong JD.
- **Giải pháp: Cascade Salary Extraction 3 Tầng**

```
[Tầng 1: Header Regex] ----> (Nếu có số cụ thể) ----> [Gán salary_min / salary_max]
        | (Nếu "Thỏa thuận" / null)
        ▼
[Tầng 2: JD Regex Scanner] -> (Quét mô tả & yêu cầu) -> [Bóc tách dải số lương ẩn]
        | (Nếu phát hiện cụm từ 'Lương năm')
        ▼
[Tầng 3: Annual Normalizer] -> Chia cho 12 tháng để quy đồng về chuẩn tháng
```

- **Kết quả:** Gia tăng tỷ lệ có dữ liệu lương định lượng từ **35.2% lên 58.6%** mà không làm thay đổi bản chất thỏa thuận gốc (`is_salary_negotiable_declared = 1`).

5. Giai Đoạn 2: Chuẩn Hóa Ngoại Tệ & Chu Kỳ Lương

- **Quy đổi ngoại tệ về VND:**
  - **USD:** Áp dụng tỷ giá tham chiếu dự án:

$$\text{Salary}_{\text{VND}} = \text{Salary}_{\text{USD}} \times 25,400 \text{ VND}$$

  - **SGD (Đô la Singapore):** Tích hợp API lịch sử Frankfurter (`api.frankfurter.dev/v1`) lấy tỷ giá chéo SGD/USD theo ngày đăng tin $\times 25,400$ VND.
- **Chuẩn hóa chu kỳ trả lương:**
  - Lương năm $\rightarrow$ Chia 12 tháng: $\text{Salary}_{\text{Month}} = \text{Salary}_{\text{Year}}/12$.
  - Lương giờ $\rightarrow$ Giả định 160 giờ/tháng (nếu có).
- **Minh bạch nguồn gốc (Data Lineage):** Lưu trữ đồng thời `salary_min_original` , `salary_max_original` , `salary_currency_original` và metadata tỷ giá.

6. Giai Đoạn 3: Bóc Trần 9+ Sneaky Null Markers

- **Hiện tượng:** Sàn tuyển dụng không để giá trị rỗng (`None`) mà điền các chuỗi ngụy trang, khiến các hàm `df.isna()` của Pandas hoàn toàn bị vô hiệu hóa!
- **Bóc trần 9+ Dạng Null Trá Hình:**
  - Dạng chữ: `"thỏa thuận"`, `"cạnh tranh"`, `"lương thương lượng"`, `"negotiable"`.
  - Dạng số / ký tự: `0`, `-1`, `"0.0"`, `"[]"`, `"{}"`, `"undefined"`, `"null"`.
- **Cơ chế khuyết thiếu MNAR (Missing Not At Random):**
  - Lương thỏa thuận **không phải** là thiếu ngẫu nhiên, mà là chiến lược bảo mật của doanh nghiệp.
  - **Giải pháp:** Reset giá trị số về `null`, đồng thời bật cờ bảo toàn:

$$\text{is_salary_negotiable} = \text{True}$$

  - **Tuyệt đối CẤM:** Không được fill Mean/Median vào các ô này vì sẽ bóp méo toàn bộ bức tranh phân phối lương thị trường.

7. Giai Đoạn 3: Kiểm Định Ngoại Lai & Winsorization

- **Bản chất: Phân tích căn nguyên ngoại lai (Root Cause Analysis):**
  - **Lương cao vượt ngưỡng:** Vị trí cấp cao (*Senior, Tech Lead, Architect, FDI*) $\rightarrow$ Dữ liệu thực tế quý giá phản ánh đỉnh trần thị trường (SD2).
  - **Lương thấp bất thường:** Trợ cấp thực tập sinh (*Intern: 2 - 4 triệu*), part-time $\rightarrow$ Dữ liệu thực hợp lệ phân khúc sinh viên (SD4).
  - **Tin rác / Bóc nhầm SĐT:** Heuristic Scrubber reset lương về `null` $\rightarrow$ Vẫn giữ dòng để bảo toàn Kỹ năng (SD3).
- **Kiểm định IQR & Kỹ thuật Winsorization tại P1 - P99:**

$$\text{IQR} = Q_3 - Q_1 \quad \Longrightarrow \quad \text{Salary}_{\text{capped}} = \min(\max(\text{Salary}, P_1), P_{99})$$

- **Chính sách Không Mất Bản Ghi (Zero Record Loss Policy):**
  - Tuyệt đối **không drop dòng**. Dải lương được khống chế an toàn trong khoảng **4 triệu** $\rightarrow$ **120 triệu VND/tháng**, bảo toàn trọn vẹn 100% bản ghi cho khai phá kỹ năng.

8. Giai Đoạn 3: Vòng Lặp Phản Hồi & Heuristic Scrubber

- **Phát hiện thực nghiệm:** Khảo sát sau khi parse lương phát hiện 2 lỗi dị biệt nghiêm trọng:
  1. *Bắt nhầm số điện thoại HR:* Câu JD có dạng *"Liên hệ Khánh Lương SĐT 0243.936.6990"* $\rightarrow$ Regex bắt nhầm thành lương **243 triệu VND**!
  2. *Bắt nhầm số che giấu:* Câu JD có dạng *"Lương từ 1*** USD"* $\rightarrow$ Bị bóc nhầm thành **25,400 VND** (1 USD)!
- **Cơ chế Phản hồi Vòng lặp (Cyclic Feedback Loop):**
  - Xây dựng bộ lọc **Heuristic Scrubber** trước khi tính toán phân vị:
  - Nhận diện pattern số điện thoại (đầu số 024, 028, 09x, 03x) và dấu sao che giấu `***`.
  - Tự động hoàn tác (reset) lương về `None` và kích hoạt lại cờ `is_salary_negotiable = True`.
- **Ý nghĩa:** Chứng minh quy trình Data Mining hiện đại là **vòng tròn phản hồi thích ứng**, không phải đường thẳng cứng nhắc.

9. Giai Đoạn 3.5: Gemini All-in-One Preprocessing Agent

- **Sứ mệnh:** Đọc hiểu ngữ nghĩa sâu văn bản JD để giải quyết 4 bài toán lớn trong **một lần duyệt duy nhất**:

1. Phân Loại Kỹ Năng 3 Lớp

- **Hard Skills:** Giữ nguyên tiếng Anh chuẩn (Python, Docker, AWS, React, Kubernetes).
- **Soft Skills:** Tiếng Việt (Giao tiếp, Làm việc nhóm, Giải quyết vấn đề).
- **Domain Skills:** Tiếng Việt (Fintech, E-commerce, EdTech, Logistics).

2. Làm Giàu Yêu Cầu (Requirements)

- `experience_years`: Chuẩn hóa số thực (0.0 cho Fresher/Intern).
- `standardized_seniority`: 7 bậc chuẩn.
- `standardized_education`: Đại học, Cao đẳng, Thạc sĩ, Không yêu cầu.

10. Giai Đoạn 3.5: Market Anchor Calculator

- **Vấn đề của LLM thuần túy:** Nếu để LLM tự đoán mức lương, nguy cơ xảy ra hiện tượng **ảo giác (Hallucination)** là rất cao!
- **Giải pháp: Khung Tham Chiếu Phân Tầng 4 Cấp (Hierarchical Market Anchors)**

```
[Cấp 1: Khớp chính xác cả Sàn Tuyển Dụng & Cấp Bậc] (nếu n >= 15 mẫu có lương thực)
        | (Nếu thiếu mẫu)
        ▼
[Cấp 2: Khớp theo Cấp Bậc toàn thị trường] (Seniority Overall Median)
        | (Nếu không rõ cấp bậc)
        ▼
[Cấp 3: Khớp theo Trung vị Sàn Tuyển Dụng] (Platform Overall Median)
        | (Fallback cuối cùng)
        ▼
[Cấp 4: Khung Lương Sàn Lý Thuyết IT Việt Nam] (Intern: 3-6M, Junior: 10-18M, Senior: 30-55M...)
```

- **Kết quả:** Lương được dự đoán luôn dao động trong **vùng an toàn thực tế của thị trường IT Việt Nam**, bảo toàn độ tin cậy khoa học.

11. Giai Đoạn 4: Khử Trùng Lặp Ngữ Nghĩa Xuyên Sàn

- **Bản chất bài toán:** 1 vị trí tuyển dụng thường được nhà tuyển dụng đăng chéo trên TopCV, VietnamWorks, TopDev và ITviec với tiêu đề hơi khác nhau.
- **Quy trình Khử trùng lặp 2 Bước (Entity Resolution Pipeline):**
  1. **Lọc thô (Blocking):** Nhóm bài đăng theo `normalized_company` và `province` địa phương để giảm độ phức tạp từ $\mathcal{O}(N^2)$ xuống $\mathcal{O}(K \cdot M^2)$.
  2. **So khớp ngữ nghĩa sâu:** Tính khoảng cách **Cosine Similarity** trên vector nhúng văn bản mô tả công việc (Text Embeddings):

$$\text{Cosine Sim}(u, v) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\|\|\mathbf{v}\|} \geq 0.82$$

  3. **Hợp nhất Bản ghi Vàng (Golden Record Selection):** Giữ lại bài đăng có độ phong phú thông tin cao nhất.
- **Kết quả thực tế:** Phát hiện và loại bỏ chính xác **1,057 bài đăng trùng lặp** (10.54%), bảo đảm tính nguyên bản cho các thuật toán Data Mining.

12. Giai Đoạn 4: Target Schema Chuẩn 11 Khóa Tinh Gọn

Toàn bộ các trường trung gian, cờ kỹ thuật và cột thô `raw_*` được loại bỏ hoàn toàn, đóng gói dữ liệu về **11 Khóa Gốc Chuẩn Mực**:


```
{
  "job_id_global": "topcv_123456",
  "source_platform": "topcv",
  "source_url": "https://...",
  "job_info": { "title": "Senior Java Backend Engineer", "job_family": "backend", "work_type": "full_time", "is_remote": false },
  "company": { "name": "FPT Software", "industry": "IT - Phần mềm", "size": "1000+" },
  "locations": [ { "province": "Hà Nội", "district": "Cầu Giấy", "Details_address": "Duy Tân" } ],
  "salary": { "salary_min": 35000000.0, "salary_max": 50000000.0, "salary_currency": "VND", "salary_source": "original" },
  "skills": { "hard_skills": ["Java", "Spring Boot", "Docker", "Kafka"], "soft_skills": ["Làm việc nhóm"], "domain_skills": ["Fintech"] },
  "requirements": { "experience_years": 4.0, "standardized_seniority": "senior", "standardized_education": "bachelor", "is_saturday_work": false },
  "jd_text": { "language": "vi", "description": "...", "requirements": "...", "benefits": "..." },
  "date": { "posted_date": "2026-10-15", "expired_date": "2026-11-15" }
}
```

13. Kiểm Định Chất Lượng Đường Ống (QA 5/5 PASSED)

Báo cáo kiểm định chất lượng tự động (`reports/qa/qa_pipeline_report.md`):

Bộ Kiểm Định (Check Suite)	Mục Tiêu Kỹ Thuật	Kết Quả Đo Lường	Trạng Thái
Check 1: Lineage & Integrity	Bảo toàn ID từ F1 sang F2; tỷ lệ khử trùng F2 → F3	100% ID preserved; Giảm 10.54% trùng	**PASSED (0 lỗi)**
Check 2: PURE JSON RFC 8259	Cấm Parquet/CSV, quét sâu đệ quy tìm hằng số `NaN`	`0` Parquet, `0` NaN (100% null RFC 8259)	**PASSED (0 lỗi)**
Check 3: Golden Master Contract	Khớp 11 root keys, sạch tiền tố phúc lợi, zero `raw_*`	`0` bản ghi vi phạm cấu trúc	**PASSED (0 lỗi)**
Check 4: Domain Groups & MNAR	10 nhóm nghiệp vụ, bảo toàn MNAR lương thỏa thuận	100% tuân thủ MNAR & Zero-Null	**PASSED (0 lỗi)**
Check 5: Outlier Governance	Tuân thủ luật chất lượng QR1-QR5, Winsorization	100% lương nằm trong vùng hợp lệ	**PASSED (0 lỗi)**

14. Bảng So Sánh Chỉ Số Chất Lượng (Trước vs Sau)

Tiêu Chí Đánh Giá	Dữ Liệu Thô Ban Đầu (Raw)	Bộ Dữ Liệu Vàng (Golden Master)	Mức Độ Cải Thiện
Số lượng bản ghi	10,024 bản ghi (lẫn trùng lặp)	**8,967 bản ghi độc bản**	Loại bỏ 1,057 tin trùng lặp
Độ phủ dữ liệu lương	35.2% (đa phần thỏa thuận)	100.0% **(Original + Predicted)**	Tăng trưởng $+64.8\%$
Độ lệch phân phối lương (Skewness)	> 5.8 (lệch phải nghiêm trọng)	0.42 **(chuẩn hóa Log-scale)**	Đưa về phân phối chuẩn đối xứng
Độ phủ số năm kinh nghiệm	48.5%	100.0% **(Zero-Null)**	Bù khuyết trọn vẹn qua GenAI
Chuẩn hóa kỹ năng	Văn bản thô, lẫn tag rác sàn	**3 lớp độc lập (Hard/Soft/Domain)**	Lọc bỏ 100% portal noise
Chuẩn hóa địa bàn	Chuỗi địa chỉ tự do	**Phân cấp Tỉnh/Thành 63 tỉnh**	Thống nhất 100% địa giới

15. Kết Luận & Sẵn Sàng Cho 5 Mục Tiêu SD1 — SD5

- **Đóng góp chính của giai đoạn Tiền xử lý:**
  1. Thiết lập **Kiến trúc Pipeline 4 bước hiện đại** với ranh giới đanh thép và vòng lặp phản hồi.
  2. Hiện thực hóa **Cascade Salary Parser** và giải pháp **Winsorization Zero Record Loss**.
  3. Đột phá ứng dụng **Gemini All-in-One Preprocessing Agent** kết hợp **Market Anchor Calculator**.
  4. Xuất bản **Bộ Dữ Liệu Vàng 8,967 bản ghi** chuẩn 11 khóa tinh gọn, vượt qua 5/5 bài test QA.
- **Sẵn sàng trọn vẹn cho giai đoạn Khai phá Chuyên sâu (Data Mining Phase):**
  - **SD1:** Tích hợp dữ liệu thị trường $\longrightarrow$ Hoàn thành xuất sắc.
  - **SD2:** Phân tích nhu cầu nghề nghiệp 12 Job Family & 7 Seniority levels.
  - **SD3:** Trí tuệ kỹ năng (Skill Intelligence) qua luật kết hợp FP-Growth & Co-occurrence.